

House Price Estimation in Yogyakarta Using a Combination of Random Forest and Extreme Gradient Boosting Tree (XGBoost) Models

Estimasi Harga Rumah di Yogyakarta Menggunakan Kombinasi Model Random Forest dan Extreme Gradient Boosting Tree (XGBoost)

Kevin Ariel Yap¹, Nur Heri Cahyana, S.T., M.Kom.², Wilis Kaswidjanti, S.Si., M.Kom.³, Dr. Heriyanto, A. Md., S.Kom., M.Cs.⁴, Frans Richard K, S.T., M.Kom., Ph.D.⁵

^{1,2,3,4,5} Informatika, Universitas Pembangunan Nasional Veteran Yogyakarta, Indonesia

¹123200105@student.upnyk.ac.id, ²nur.hericahyana@upnyk.ac.id, ³wilisk@upnyk.ac.id, ⁴heriyanto@upnyk.ac.id, ⁵frans.ricard@upnyk.ac.id

Informasi Artikel

Received:

Revised:

Accepted:

Published:

Abstract

Purpose: This study aims to estimate house prices in Yogyakarta by applying a combination of machine learning models, namely Random Forest and Extreme Gradient Boosting Tree (XGBoost), through ensemble techniques including a meta-model approach.

Design/methodology/approach: The study uses a dataset collected from an online property platform, containing features such as land area, building size, number of rooms, and certificate type. The data undergoes preprocessing including normalization, encoding, and handling of missing values. Modeling is conducted using Random Forest and XGBoost individually, then combined using both averaging and a meta-model strategy. Performance is evaluated using MAE, RMSE, and R^2 .

Findings/result: The meta-model approach outperforms individual models and the averaging ensemble, achieving the lowest error rates and the highest R^2 value. This confirms the advantage of combining model predictions through a learning-based strategy.

Originality/value/state of the art: This study offers a practical ensemble learning framework for house price estimation in urban Indonesia, highlighting the strength of meta-modeling to reduce prediction error and improve generalization, especially in real estate contexts with heterogeneous attributes.

Abstrak

Keywords: Image Classification, SVM, HSV, GLRLM, Corn Seeds.

Tujuan: Penelitian ini bertujuan untuk mengestimasi harga rumah di Yogyakarta dengan menerapkan kombinasi model

Kata kunci: Klasifikasi Citra, SVM, HSV, GLRLM, Biji Jagung.

machine learning, yaitu Random Forest dan Extreme Gradient Boosting Tree (XGBoost), melalui teknik ensemble termasuk pendekatan meta-model.

Perancangan/metode/pendekatan: Studi ini menggunakan dataset yang diperoleh dari platform properti daring, yang mencakup fitur seperti luas tanah, luas bangunan, jumlah kamar, dan jenis sertifikat. Data diproses melalui tahapan praproses seperti normalisasi, encoding, dan penanganan nilai kosong. Pemodelan dilakukan menggunakan Random Forest dan XGBoost secara individual, kemudian digabungkan menggunakan pendekatan rata-rata dan meta-model. Evaluasi performa dilakukan dengan menggunakan MAE, RMSE, dan R^2 .

Hasil: Pendekatan meta-model memberikan hasil yang lebih baik dibandingkan model individual maupun ensemble rata-rata, dengan tingkat kesalahan terendah dan nilai R^2 tertinggi. Hal ini menunjukkan keunggulan strategi kombinasi prediksi berbasis pembelajaran.

Keaslian/ state of the art: Penelitian ini menawarkan kerangka kerja ensemble learning yang praktis untuk estimasi harga rumah di kawasan perkotaan Indonesia, serta menyoroti keunggulan meta-modeling dalam menurunkan kesalahan prediksi dan meningkatkan generalisasi, khususnya dalam konteks real estate dengan atribut yang beragam.

1. Pendahuluan

Permintaan terhadap hunian semakin meningkat seiring dengan pertumbuhan penduduk dan urbanisasi yang pesat, khususnya di wilayah perkotaan seperti Yogyakarta. Kota ini merupakan salah satu daerah tujuan utama baik untuk pendidikan, pariwisata, maupun investasi properti. Tingginya kebutuhan akan tempat tinggal mendorong naiknya harga rumah, sehingga estimasi harga rumah menjadi hal yang sangat penting bagi berbagai pihak, seperti pembeli, penjual, agen properti, hingga pengembang. Namun, dalam praktiknya, penentuan harga rumah sering kali dilakukan secara subjektif atau hanya berdasarkan pengalaman pribadi, yang dapat menyebabkan ketidaksesuaian harga dengan nilai pasar yang sebenarnya. Oleh karena itu, diperlukan metode yang dapat mengestimasi harga rumah secara lebih objektif dan akurat.

Penelitian sebelumnya telah banyak dilakukan untuk mengatasi permasalahan ini menggunakan pendekatan statistik dan algoritma pembelajaran mesin (machine learning). Misalnya, penelitian oleh [1] menggunakan metode regresi linear untuk memprediksi harga rumah berdasarkan fitur dasar seperti luas bangunan dan jumlah kamar. Namun, metode linear seringkali tidak mampu menangkap hubungan kompleks antar variabel. Penelitian oleh [2] menunjukkan bahwa metode Random Forest mampu meningkatkan akurasi estimasi harga karena dapat memodelkan hubungan non-linear dan menangani fitur dalam jumlah besar. Di sisi lain, metode Extreme

Gradient Boosting Tree (XGBoost) yang dikembangkan oleh [3] juga terbukti sangat efektif dalam berbagai kompetisi data karena kemampuannya dalam mengurangi overfitting dan menghasilkan prediksi yang stabil.

Beberapa studi telah menggabungkan dua atau lebih algoritma dalam pendekatan ensemble untuk meningkatkan performa model. Pendekatan ensemble seperti model rata-rata (averaging) dan meta-modeling (stacking) mampu menggabungkan kelebihan dari masing-masing algoritma dasar sehingga menghasilkan prediksi yang lebih baik dibandingkan penggunaan satu model tunggal [4]. Penelitian oleh [5] menggunakan stacking model dengan Random Forest dan XGBoost untuk prediksi harga rumah di luar negeri dan memperoleh peningkatan performa yang signifikan. Namun, penerapan metode tersebut pada konteks lokal seperti di Yogyakarta masih sangat terbatas.

Berdasarkan penelitian-penelitian yang telah dilakukan sebelumnya, penelitian ini bertujuan untuk mengimplementasikan kombinasi model Random Forest dan XGBoost menggunakan teknik ensemble seperti rata-rata dan meta-model untuk estimasi harga rumah di Yogyakarta. Diharapkan pendekatan ini dapat memberikan estimasi harga yang lebih akurat dan membantu dalam pengambilan keputusan baik bagi individu maupun instansi yang bergerak di bidang properti.


2. Metode Penelitian

Metodologi penelitian pada studi ini terdiri dari beberapa tahapan yang menggambarkan proses secara sistematis dalam membangun model estimasi harga rumah. Penelitian dimulai dari tahap analisis masalah, yaitu dengan mengidentifikasi pentingnya estimasi harga rumah yang akurat di wilayah Yogyakarta. Selanjutnya, dilakukan pengumpulan data properti dari situs web real estate yang mencakup berbagai fitur seperti harga, lokasi, luas tanah, luas bangunan, jumlah kamar, jumlah kamar mandi, daya listrik, jenis interior, sertifikat, dan fasilitas parkir.

Tahapan berikutnya adalah preprocessing data untuk mempersiapkan data agar dapat digunakan dalam pemodelan. Proses preprocessing mencakup pembersihan data (handling missing values), encoding data kategorikal, normalisasi fitur numerik, serta penghapusan data duplikat. Tujuan dari preprocessing ini adalah untuk memastikan bahwa data yang digunakan berada dalam format yang konsisten dan siap untuk diolah oleh algoritma machine learning.

Setelah data siap, proses dilanjutkan dengan pelatihan model menggunakan dua algoritma utama, yaitu Random Forest dan Extreme Gradient Boosting Tree (XGBoost). Kedua algoritma ini dilatih secara terpisah terlebih dahulu dengan menggunakan data pelatihan. Setelah itu, dilakukan penggabungan prediksi dari kedua model tersebut melalui dua pendekatan: pertama, menggunakan rata-rata dari hasil prediksi (average ensemble), dan kedua, menggunakan meta-model (stacking) dengan algoritma tambahan sebagai penggabung prediksi, yaitu menggunakan model regresi linier.

Langkah selanjutnya adalah evaluasi model. Evaluasi dilakukan dengan menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan koefisien determinasi (R^2) untuk mengukur seberapa baik model dalam melakukan estimasi harga rumah. Model dengan nilai MAE dan RMSE paling kecil serta R^2 paling mendekati 1 dianggap sebagai model dengan performa terbaik. Evaluasi dilakukan tidak hanya pada model individual, tetapi juga pada model gabungan untuk mengetahui efektivitas pendekatan ensemble.



Gambar 1. Metodologi Penelitian

2.1. Pengumpulan Data

Pada penelitian ini, proses pengumpulan data menggunakan dataset sekunder yang diperoleh dari situs web properti <https://www.99.co/id>. Dataset tersebut berisi informasi mengenai properti rumah dijual di wilayah Kota Yogyakarta. Total data yang berhasil dikumpulkan berjumlah 4.082 data, masing-masing mencakup berbagai atribut penting seperti harga rumah, lokasi, luas tanah, luas bangunan, jumlah kamar tidur, jumlah kamar mandi, kapasitas parkir, daya listrik, tipe interior, jenis sertifikat, dan jumlah lahan parkir.

Data yang diperoleh memiliki format yang tidak seragam dan terdapat atribut yang memiliki nilai kosong, tidak relevan, atau duplikat. Oleh karena itu, dilakukan proses pembersihan data untuk memastikan kualitas dataset sebelum diproses lebih lanjut. Seluruh data yang digunakan hanya mencakup properti dengan satuan rumah tinggal dan tidak mencakup properti komersial, apartemen, atau tanah kosong. Dataset ini digunakan sebagai dasar dalam membangun model estimasi harga rumah dengan metode *machine learning*.

2.2. Preprocessing Data

Tahapan preprocessing merupakan proses penting untuk membersihkan dan mempersiapkan data sebelum dimasukkan ke dalam model machine learning agar menghasilkan model estimasi harga rumah yang akurat. Langkah pertama yang dilakukan adalah pemeriksaan dan

penghapusan data duplikat serta data kosong yang dapat mengganggu proses pembelajaran model. Selanjutnya, dilakukan proses pemberian label numerik pada atribut kategorikal seperti *interior* (misalnya: furnished, semi-furnished, unfurnished) dan *sertifikat* (misalnya: SHM, SHGB), agar data dapat diproses oleh algoritma pembelajaran mesin.

Tahapan berikutnya adalah proses standardisasi dan normalisasi data numerik seperti *luas tanah*, *luas bangunan*, *harga*, dan *daya listrik* agar memiliki skala yang seragam. Hal ini penting agar algoritma seperti Random Forest dan XGBoost dapat mengolah semua fitur dengan bobot yang seimbang. Setelah data dinyatakan bersih dan dalam format yang sesuai, dataset dibagi menjadi dua bagian, yaitu data latih (training) dan data uji (testing) dengan perbandingan 80:20 untuk memvalidasi performa model secara objektif.

2.3. Modelling

Pada tahap ini, algoritma Random Forest dan Extreme Gradient Boosting Tree (XGBoost) diimplementasikan untuk membangun model estimasi harga rumah di Yogyakarta. Keputusan untuk menggabungkan Random Forest dengan XGBoost didasarkan pada beberapa faktor penting, yaitu:

1. Kemampuan Random Forest Mengatasi Overfitting

Random Forest menggunakan teknik ensemble learning dengan membangun beberapa pohon keputusan acak dan menggabungkan prediksi mereka. Dalam konteks estimasi harga rumah, Random Forest dapat mengurangi risiko overfitting yang mungkin terjadi akibat variasi dalam data training.

2. Kemampuan Random Forest Menangani Fitur Tidak Linear

Random Forest dapat menangani hubungan kompleks antara fitur-fitur dan target estimasi. Dalam hal estimasi harga rumah, fitur seperti luas bangunan, jumlah kamar, dan lokasi sering kali memiliki hubungan yang tidak linier dengan harga rumah. Random Forest mampu menangkap hubungan ini lebih baik dibandingkan model linear seperti regresi linier.

3. Peningkatan Performa dengan Menggabungkan XGBoost

Penggabungan dengan XGBoost dilakukan untuk memanfaatkan kekuatan model yang berbeda dan meningkatkan performa estimasi. XGBoost, sebagai metode ensemble learning lain, mengatasi kelemahan model tunggal dengan menggabungkan beberapa model sederhana menjadi satu model yang lebih kuat. Dalam konteks ini, penggabungan hasil estimasi dari Random Forest dan XGBoost dapat meningkatkan kemampuan model dalam menangkap pola dan variabilitas dalam data harga rumah.

2.4. Random Forest

Random Forest merupakan algoritma ensemble yang membangun sejumlah pohon keputusan (*decision tree*) secara acak dan menggabungkan hasilnya melalui rata-rata (*mean*) prediksi. Model ini dipilih karena mampu menangani data non-linear dan multivariat secara efektif.

Proses tuning dilakukan menggunakan GridSearchCV dengan parameter sebagai berikut:

- `n_estimators`: [100, 200, 300]

- max_depth: [10, 20, None]
- min_samples_split: [2, 5, 10]

Model terbaik diperoleh berdasarkan nilai *Coefficient of Determination* (R^2) terkecil pada data validasi.

2.5. XGBoost

XGBoost merupakan metode boosting yang bekerja secara iteratif dengan menambahkan model baru untuk memperbaiki kesalahan dari model sebelumnya. Keunggulan utama XGBoost adalah kemampuannya menangani overfitting melalui regularisasi serta efisiensi komputasi yang tinggi.

Parameter yang dituning mencakup:

- n_estimators: [100, 200]
- learning_rate: [0.05, 0.1]
- max_depth: [3, 6]
- subsample: [0.8, 1.0]
- colsample_bytree: [0.8, 1.0]

Pemilihan parameter terbaik juga didasarkan pada nilai (R^2) terendah.

2.6. Meta-Model

Setelah memperoleh model terbaik dari Random Forest dan XGBoost, penggabungan kedua model dilakukan untuk meningkatkan akurasi estimasi harga rumah. Estimasi dari kedua model digunakan sebagai fitur masukan pada meta-model, yang diinisialisasi dengan menggunakan Random Forest Regressor. Model ini dilatih dengan data hasil estimasi dari Random Forest dan XGBoost, kemudian digunakan untuk menghasilkan estimasi harga rumah yang lebih akurat.

3. Hasil dan Pembahasan

Bagian ini menjelaskan implementasi, pembahasan, dan hasil dari perancangan sistem estimasi harga rumah yang telah dilakukan, mencakup tahap studi literatur, pengumpulan data, preprocessing, pembangunan model, serta analisis dan evaluasi hasil. Sistem dikembangkan menggunakan dua algoritma pembelajaran mesin, yaitu Random Forest dan XGBoost, yang dilatih dengan dataset properti rumah di Yogyakarta untuk menghasilkan estimasi harga rumah secara lebih akurat.

3.1. Pengujian

Pada bagian ini dijelaskan pengujian yang dilakukan terhadap penelitian dan hasilnya. Pengujian dilakukan terhadap model dan pengujian sistem.

3.1.1. Pengujian Model

Setelah pelatihan, model dievaluasi menggunakan MAPE, R^2 , MAE, dan RMSE. Model default menunjukkan overfitting: akurat di data latih, namun buruk di data uji. Setelah tuning, performa model pada data uji meningkat signifikan, khususnya pada MAPE dan R^2 , yang menunjukkan generalisasi lebih baik. Meski MAE dan RMSE masih tinggi, hal ini dipengaruhi

oleh skala harga rumah yang besar dan adanya outlier. Secara keseluruhan, kombinasi model yang telah dituning menghasilkan estimasi yang lebih stabil dan seimbang.

Tabel 1. Hasil Pengujian Dan Komparasi

Matriks	Random Forest	XGBoost	Meta-Model
MAPE	0.1402	0.1248	0.1223
R ² Score	0.8161	0.8317	0.8299
MAE	Rp 120.085.705	Rp 105.371.216	Rp 104.089.423
RMSE	Rp 193.839.402	Rp 185.429.274	Rp 186.427.791

3.1.2. Pengujian Sistem

Sistem yang telah dibangun dan diimplementasikan setelahnya dilakukan pengujian terhadap sistem tersebut. Pengujian sistem dilakukan menggunakan metode *blackbox*, di mana pengujian fokus pada fungsi sistem tanpa memperhatikan implementasi internalnya. Pengguna memberikan input pada form yang tersedia dan sistem akan menghasilkan output berupa estimasi harga rumah. Pengujian ini bertujuan untuk memastikan bahwa aplikasi berjalan dengan baik, memberikan estimasi harga yang akurat, dan tidak ada kesalahan dalam alur *input-output* sistem.

Tabel 2. Pengujian black box

No	Fitur yang Diuji	Skenario Pengujian	Input	Ekspektasi Output	Hasil Pengujian	Status
1	Input data properti	User memasukkan data rumah di <i>form web</i>	Lokasi, luas bangunan, jumlah kamar, dll.	Data diterima dan diproses	Sesuai	Lulus
2	Pengecekan <i>cache</i> data	Sistem mengecek apakah data telah diproses sebelumnya	Data tersedia/tidak tersedia di <i>cache</i>	Jika ada, gunakan; jika tidak, lakukan <i>preprocessing</i>	Sesuai	Lulus
3	Estimasi dengan model kombinasi	Model melakukan estimasi berdasarkan data yang diinput user	Data rumah yang sudah diproses	Harga rumah yang diestimasi muncul	Sesuai	Lulus
4	Tampilan hasil estimasi	Website menampilkan hasil estimasi kepada user	Hasil estimasi dari <i>meta-model</i>	Harga rumah ditampilkan dalam format yang mudah dibaca	Sesuai	Lulus
5	Tampilkan pengaruh fitur	Halaman menampilkan pengaruh fitur kepada user	Hasil estimasi harga rumah	Pengaruh fitur ditampilkan dalam format yang mudah dibaca	Sesuai	Lulus

3.2. Pembahasan

Sistem estimasi harga rumah ini menggunakan model Random Forest dan XGBoost yang dilatih dengan data properti di Yogyakarta. Evaluasi menunjukkan bahwa nilai MAPE meta-model tercatat sebesar 12,23%, lebih baik dibandingkan Random Forest (14,02%) dan XGBoost (12,48%). Pada metrik MAE, meta-model juga unggul dengan rata-rata kesalahan sebesar Rp 104 juta, diikuti XGBoost (Rp 105 juta) dan Random Forest (Rp 120 juta). Untuk metrik RMSE, XGBoost sedikit lebih unggul (Rp 185 juta) dibanding meta-model (Rp 186 juta), sedangkan Random Forest mencatat nilai tertinggi (Rp 193 juta). Skor R^2 tertinggi juga dicapai oleh XGBoost (83,17%), diikuti meta-model (82,99%) dan Random Forest (81,61%).

Analisis EDA menunjukkan bahwa fitur seperti *luas_bangunan* dan *luas_tanah* berkorelasi cukup kuat dengan harga, namun hubungan antar fitur tidak selalu linear. Beberapa fitur memiliki distribusi yang kurang variatif, yang dapat memengaruhi performa model.

4. Kesimpulan dan Saran

Pada bagian terakhir ini, penelitian yang telah dilaksanakan disimpulkan sesuai dengan tujuan yang telah dijelaskan sebelumnya. Evaluasi dari kesimpulan hasil penelitian dilakukan untuk memberikan saran guna meningkatkan penelitian selanjutnya.

4.1. Kesimpulan

Penelitian ini berhasil mengembangkan sistem estimasi harga rumah di Yogyakarta menggunakan model Random Forest dan XGBoost. Hasil evaluasi menunjukkan bahwa MAPE meta-model tercatat paling rendah yaitu sebesar 12,23%. Pada metrik MAE, meta-model mencatat rata-rata kesalahan terendah sekitar Rp 104 juta, sementara RMSE meta-model berada di angka Rp 186 juta. Secara keseluruhan, meta-model menunjukkan keseimbangan paling optimal dari seluruh metrik evaluasi.

Meski masih terdapat tantangan terkait skala harga yang besar dan keberadaan outlier, sistem ini menunjukkan potensi yang baik dan dapat diandalkan. Temuan ini menjadi dasar bagi pengembangan lebih lanjut dalam penerapan pembelajaran mesin untuk estimasi harga properti di sektor real estate.

4.2. Saran

Beberapa saran untuk pengembangan selanjutnya meliputi:

1. Lakukan pembersihan dan validasi data secara menyeluruh, terutama dalam menangani outlier dan inkonsistensi penulisan.
2. Tambahkan fitur seperti fasilitas (kolam renang, taman), tahun pembangunan, atau jenis sertifikat untuk meningkatkan akurasi model.
3. Uji model lain seperti SVM, Gradient Boosting, atau Deep Learning untuk membandingkan performa.
4. Gunakan metode seperti Random Search atau Bayesian Optimization untuk eksplorasi parameter yang lebih efisien.
5. Gunakan data dari wilayah lain atau dataset yang lebih besar untuk menguji kemampuan generalisasi model.

Daftar Pustaka

- [1] Febrion Rahayuningtyas, E., Novia Rahayu, F., Azhar, Y., & Artikel, I. (2021). Prediksi Harga Rumah Menggunakan General Regression Neural Network. *JURNAL INFORMATIKA*, 8(1). <https://archive.ics.uci.edu/ml/datasets/Real>
- [2] Ardiansyah, F., & Komputer, I. (2024). MENGGUNAKAN ALGORITMA RANDOM FOREST UNTUK PREDIKSI HARGA PROPERTI. In *Duniadata.org* (Vol. 1, Issue 5).
- [3] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 13-17-August-2016*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [4] Lin, J., Zhong, C., Hu, D., Rudin, C., & Seltzer, M. (2020). *Generalized and Scalable Optimal Sparse Decision Trees*. <http://arxiv.org/abs/2006.08690>
- [5] Li, H. (2023). House Price Prediction and Analysis Based on Random Forest and XGBoost Models. In *Business, Economics and Management GEFHR* (Vol. 2023).