

House Price Estimation in Yogyakarta Using a Combination of Random Forest and Extreme Gradient Boosting Tree (XGBoost) Models

Estimasi Harga Rumah di Yogyakarta Menggunakan Kombinasi Model Random Forest dan Extreme Gradient Boosting Tree (XGBoost)

Kevin Ariel Yap¹, Nur Heri Cahyana, S.T., M.Kom.², Wilis Kaswidjanti, S.Si., M.Kom.³, Dr. Heriyanto, A. Md., S.Kom., M.Cs.⁴, Frans Richard K, S.T., M.Kom., Ph.D.⁵

^{1,2,3,4,5} Informatika, Universitas Pembangunan Nasional Veteran Yogyakarta, Indonesia

¹123200105@student.upnyk.ac.id, ²nur.hericaHYANA@upnyk.ac.id, ³wilisk@upnyk.ac.id, ⁴heriyanto@upnyk.ac.id, ⁵frans.ricard@upnyk.ac.id

Informasi Artikel

Received:

Revised:

Accepted:

Published:

Abstract

Purpose: This study aims to estimate house prices in Yogyakarta by applying a combination of machine learning models, namely Random Forest and Extreme Gradient Boosting Tree (XGBoost), through ensemble techniques including a meta-model approach.

Design/methodology/approach: The study uses a dataset collected from an online property platform, containing features such as land area, building size, number of rooms, and certificate type. The data undergoes preprocessing including normalization, encoding, and handling of missing values. Modeling is conducted using Random Forest and XGBoost individually, then combined using both averaging and a meta-model strategy. Performance is evaluated using MAE, RMSE, and R^2 .

Findings/result: The meta-model approach outperforms individual models and the averaging ensemble, achieving the lowest error rates and the highest R^2 value. This confirms the advantage of combining model predictions through a learning-based strategy.

Originality/value/state of the art: This study offers a practical ensemble learning framework for house price estimation in urban Indonesia, highlighting the strength of meta-modeling to reduce prediction error and improve generalization, especially in real estate contexts with heterogeneous attributes.

Abstrak

Keywords: Image Classification, SVM, HSV, GLRLM, Corn Seeds.

Tujuan: Penelitian ini bertujuan untuk mengestimasi harga rumah di Yogyakarta dengan menerapkan kombinasi model

Kata kunci: Klasifikasi Citra, SVM, HSV, GLRLM, Biji Jagung.

machine learning, yaitu Random Forest dan Extreme Gradient Boosting Tree (XGBoost), melalui teknik ensemble termasuk pendekatan meta-model.

Perancangan/metode/pendekatan: Studi ini menggunakan dataset yang diperoleh dari platform properti daring, yang mencakup fitur seperti luas tanah, luas bangunan, jumlah kamar, dan jenis sertifikat. Data diproses melalui tahapan praproses seperti normalisasi, encoding, dan penanganan nilai kosong. Pemodelan dilakukan menggunakan Random Forest dan XGBoost secara individual, kemudian digabungkan menggunakan pendekatan rata-rata dan meta-model. Evaluasi performa dilakukan dengan menggunakan MAE, RMSE, dan R^2 .

Hasil: Pendekatan meta-model memberikan hasil yang lebih baik dibandingkan model individual maupun ensemble rata-rata, dengan tingkat kesalahan terendah dan nilai R^2 tertinggi. Hal ini menunjukkan keunggulan strategi kombinasi prediksi berbasis pembelajaran.

Keaslian/ state of the art: Penelitian ini menawarkan kerangka kerja ensemble learning yang praktis untuk estimasi harga rumah di kawasan perkotaan Indonesia, serta menyoroti keunggulan meta-modeling dalam menurunkan kesalahan prediksi dan meningkatkan generalisasi, khususnya dalam konteks real estate dengan atribut yang beragam.

1. Pendahuluan

Permintaan terhadap hunian semakin meningkat seiring dengan pertumbuhan penduduk dan urbanisasi yang pesat, khususnya di wilayah perkotaan seperti Yogyakarta. Kota ini merupakan salah satu daerah tujuan utama baik untuk pendidikan, pariwisata, maupun investasi properti. Tingginya kebutuhan akan tempat tinggal mendorong naiknya harga rumah, sehingga estimasi harga rumah menjadi hal yang sangat penting bagi berbagai pihak, seperti pembeli, penjual, agen properti, hingga pengembang. Namun, dalam praktiknya, penentuan harga rumah sering kali dilakukan secara subjektif atau hanya berdasarkan pengalaman pribadi, yang dapat menyebabkan ketidaksesuaian harga dengan nilai pasar yang sebenarnya. Oleh karena itu, diperlukan metode yang dapat mengestimasi harga rumah secara lebih objektif dan akurat.

Penelitian sebelumnya telah banyak dilakukan untuk mengatasi permasalahan ini menggunakan pendekatan statistik dan algoritma pembelajaran mesin (machine learning). Misalnya, penelitian oleh [1] menggunakan metode regresi linear untuk memprediksi harga rumah berdasarkan fitur dasar seperti luas bangunan dan jumlah kamar. Namun, metode linear seringkali tidak mampu menangkap hubungan kompleks antar variabel. Penelitian oleh [2] menunjukkan bahwa metode Random Forest mampu meningkatkan akurasi estimasi harga karena dapat memodelkan hubungan non-linear dan menangani fitur dalam jumlah besar. Di sisi lain, metode Extreme

Gradient Boosting Tree (XGBoost) yang dikembangkan oleh [3] juga terbukti sangat efektif dalam berbagai kompetisi data karena kemampuannya dalam mengurangi overfitting dan menghasilkan prediksi yang stabil.

Beberapa studi telah menggabungkan dua atau lebih algoritma dalam pendekatan ensemble untuk meningkatkan performa model. Pendekatan ensemble seperti model rata-rata (averaging) dan meta-modeling (stacking) mampu menggabungkan kelebihan dari masing-masing algoritma dasar sehingga menghasilkan prediksi yang lebih baik dibandingkan penggunaan satu model tunggal [4]. Penelitian oleh [5] menggunakan stacking model dengan Random Forest dan XGBoost untuk prediksi harga rumah di luar negeri dan memperoleh peningkatan performa yang signifikan. Namun, penerapan metode tersebut pada konteks lokal seperti di Yogyakarta masih sangat terbatas.

Berdasarkan penelitian-penelitian yang telah dilakukan sebelumnya, penelitian ini bertujuan untuk mengimplementasikan kombinasi model Random Forest dan XGBoost menggunakan teknik ensemble seperti rata-rata dan meta-model untuk estimasi harga rumah di Yogyakarta. Diharapkan pendekatan ini dapat memberikan estimasi harga yang lebih akurat dan membantu dalam pengambilan keputusan baik bagi individu maupun instansi yang bergerak di bidang properti.


2. Metode Penelitian

Metodologi penelitian pada studi ini terdiri dari beberapa tahapan yang menggambarkan proses secara sistematis dalam membangun model estimasi harga rumah. Penelitian dimulai dari tahap analisis masalah, yaitu dengan mengidentifikasi pentingnya estimasi harga rumah yang akurat di wilayah Yogyakarta. Selanjutnya, dilakukan pengumpulan data properti dari situs web real estate yang mencakup berbagai fitur seperti harga, lokasi, luas tanah, luas bangunan, jumlah kamar, jumlah kamar mandi, daya listrik, jenis interior, sertifikat, dan fasilitas parkir.

Tahapan berikutnya adalah preprocessing data untuk mempersiapkan data agar dapat digunakan dalam pemodelan. Proses preprocessing mencakup pembersihan data (handling missing values), encoding data kategorikal, normalisasi fitur numerik, serta penghapusan data duplikat. Tujuan dari preprocessing ini adalah untuk memastikan bahwa data yang digunakan berada dalam format yang konsisten dan siap untuk diolah oleh algoritma machine learning.

Setelah data siap, proses dilanjutkan dengan pelatihan model menggunakan dua algoritma utama, yaitu Random Forest dan Extreme Gradient Boosting Tree (XGBoost). Kedua algoritma ini dilatih secara terpisah terlebih dahulu dengan menggunakan data pelatihan. Setelah itu, dilakukan penggabungan prediksi dari kedua model tersebut melalui dua pendekatan: pertama, menggunakan rata-rata dari hasil prediksi (average ensemble), dan kedua, menggunakan meta-model (stacking) dengan algoritma tambahan sebagai penggabung prediksi, yaitu menggunakan model regresi linier.

Langkah selanjutnya adalah evaluasi model. Evaluasi dilakukan dengan menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan koefisien determinasi (R^2) untuk mengukur seberapa baik model dalam melakukan estimasi harga rumah. Model dengan nilai MAE dan RMSE paling kecil serta R^2 paling mendekati 1 dianggap sebagai model dengan performa terbaik. Evaluasi dilakukan tidak hanya pada model individual, tetapi juga pada model gabungan untuk mengetahui efektivitas pendekatan ensemble.



Gambar 1. Metodologi Penelitian

2.1. Pengumpulan Data

Pada penelitian ini, proses pengumpulan data menggunakan dataset sekunder yang diperoleh dari situs web properti <https://www.99.co/id>. Dataset tersebut berisi informasi mengenai properti rumah dijual di wilayah Kota Yogyakarta. Total data yang berhasil dikumpulkan berjumlah 4.082 data, masing-masing mencakup berbagai atribut penting seperti harga rumah, lokasi, luas tanah, luas bangunan, jumlah kamar tidur, jumlah kamar mandi, kapasitas parkir, daya listrik, tipe interior, jenis sertifikat, dan jumlah lahan parkir.

Data yang diperoleh memiliki format yang tidak seragam dan terdapat atribut yang memiliki nilai kosong, tidak relevan, atau duplikat. Oleh karena itu, dilakukan proses pembersihan data untuk memastikan kualitas dataset sebelum diproses lebih lanjut. Seluruh data yang digunakan hanya mencakup properti dengan satuan rumah tinggal dan tidak mencakup properti komersial, apartemen, atau tanah kosong. Dataset ini digunakan sebagai dasar dalam membangun model estimasi harga rumah dengan metode *machine learning*.

2.2. Preprocessing Data

Tahapan preprocessing merupakan proses penting untuk membersihkan dan mempersiapkan data sebelum dimasukkan ke dalam model machine learning agar menghasilkan model estimasi harga rumah yang akurat. Langkah pertama yang dilakukan adalah pemeriksaan dan