

penghapusan data duplikat serta data kosong yang dapat mengganggu proses pembelajaran model. Selanjutnya, dilakukan proses pemberian label numerik pada atribut kategorikal seperti *interior* (misalnya: furnished, semi-furnished, unfurnished) dan *sertifikat* (misalnya: SHM, SHGB), agar data dapat diproses oleh algoritma pembelajaran mesin.

Tahapan berikutnya adalah proses standardisasi dan normalisasi data numerik seperti *luas tanah*, *luas bangunan*, *harga*, dan *daya listrik* agar memiliki skala yang seragam. Hal ini penting agar algoritma seperti Random Forest dan XGBoost dapat mengolah semua fitur dengan bobot yang seimbang. Setelah data dinyatakan bersih dan dalam format yang sesuai, dataset dibagi menjadi dua bagian, yaitu data latih (training) dan data uji (testing) dengan perbandingan 80:20 untuk memvalidasi performa model secara objektif.

2.3. Modelling

Pada tahap ini, algoritma Random Forest dan Extreme Gradient Boosting Tree (XGBoost) diimplementasikan untuk membangun model estimasi harga rumah di Yogyakarta. Keputusan untuk menggabungkan Random Forest dengan XGBoost didasarkan pada beberapa faktor penting, yaitu:

1. Kemampuan Random Forest Mengatasi Overfitting

Random Forest menggunakan teknik ensemble learning dengan membangun beberapa pohon keputusan acak dan menggabungkan prediksi mereka. Dalam konteks estimasi harga rumah, Random Forest dapat mengurangi risiko overfitting yang mungkin terjadi akibat variasi dalam data training.

2. Kemampuan Random Forest Menangani Fitur Tidak Linear

Random Forest dapat menangani hubungan kompleks antara fitur-fitur dan target estimasi. Dalam hal estimasi harga rumah, fitur seperti luas bangunan, jumlah kamar, dan lokasi sering kali memiliki hubungan yang tidak linier dengan harga rumah. Random Forest mampu menangkap hubungan ini lebih baik dibandingkan model linear seperti regresi linier.

3. Peningkatan Performa dengan Menggabungkan XGBoost

Penggabungan dengan XGBoost dilakukan untuk memanfaatkan kekuatan model yang berbeda dan meningkatkan performa estimasi. XGBoost, sebagai metode ensemble learning lain, mengatasi kelemahan model tunggal dengan menggabungkan beberapa model sederhana menjadi satu model yang lebih kuat. Dalam konteks ini, penggabungan hasil estimasi dari Random Forest dan XGBoost dapat meningkatkan kemampuan model dalam menangkap pola dan variabilitas dalam data harga rumah.

2.4. Random Forest

Random Forest merupakan algoritma ensemble yang membangun sejumlah pohon keputusan (*decision tree*) secara acak dan menggabungkan hasilnya melalui rata-rata (*mean*) prediksi. Model ini dipilih karena mampu menangani data non-linear dan multivariat secara efektif.

Proses tuning dilakukan menggunakan GridSearchCV dengan parameter sebagai berikut:

- `n_estimators`: [100, 200, 300]